

Σύγκριση Αλγορίθμων Μηχανικής Μάθησης με Δεδομένα από το OpenML (scikit-learn)

Κωσταντίνος-Αλέξανδρος Σκαρογιάννης-Σπυρόπουλος

Αριθμός Μητρώου:1073387

Διδάσκων: Σ. Κωτσιαντής

Σκοπός της εργασίας είναι η πειραματική σύγκριση κλασικών αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης. Χρησιμοποιήθηκαν δεδομένα από το OpenM. Στόχος είναι η αξιολόγηση της απόδοσης των μοντέλων και η ανάλυση της συμπεριφοράς τους.

Μεθοδολογία

Για την εκπόνηση της εργασίας επιλέχθηκαν τρία datasets διαφορετικής δυσκολίας:

- **breast-w:** Πρόβλεψη καρκίνου του μαστού (Binary classification).
- **diabetes:** Πρόβλεψη διαβήτη (Numerical features).
- **credit-g:** Εκτίμηση πιστωτικού κινδύνου (Mixed features: αριθμητικά και κατηγορικά).

Χρησιμοποιήσαμε τρεις αλγόριθμους: k-NN, Random Forest και MLP Classifier. Για την προεπεξεργασία των δεδομένων εφαρμόστηκε συμπλήρωση ελλিপών τιμών (Imputation), κωδικοποίηση κατηγορικών μεταβλητών (One-Hot Encoding) και κανονικοποίηση (StandardScaler) και χρήση Pipeline και ColumnTransformer για την ενιαία ροή των δεδομένων. Η αξιολόγηση έγινε με τη μέθοδο 5-fold Cross-Validation. Μετρικές: Accuracy, Precision, Recall, F1-score (macro-averaged).

Ποιος αλγόριθμος παρουσίασε την καλύτερη απόδοση και γιατί;

...

--- Συγκριτικός Πίνακας Αποτελεσμάτων ---

	Dataset	Algorithm	Accuracy	Precision	Recall	F1-Score
1	breast-w	Random Forest	0.9671	0.9645	0.9641	0.9637
0	breast-w	k-NN	0.9643	0.9623	0.9600	0.9604
2	breast-w	MLP (Neural Net)	0.9643	0.9599	0.9619	0.9604
7	credit-g	Random Forest	0.7540	0.7197	0.6490	0.6604
8	credit-g	MLP (Neural Net)	0.7330	0.6783	0.6645	0.6699
6	credit-g	k-NN	0.7200	0.6564	0.6067	0.6120
5	diabetes	MLP (Neural Net)	0.7644	0.7436	0.7299	0.7349
4	diabetes	Random Forest	0.7631	0.7449	0.7185	0.7266
3	diabetes	k-NN	0.7357	0.7093	0.6923	0.6980

Από τα αποτελέσματα των πειραμάτων, ο αλγόριθμος Random Forest είχε την καλύτερη και πιο σταθερή συμπεριφορά συνολικά. Στο dataset breast-w πέτυχε τη μεγαλύτερη ακρίβεια με ποσοστό 96.71%, ενώ στο credit-g είχε 75.40%. Στο dataset diabetes ήρθε δεύτερος ως προς την ακρίβεια με ελάχιστη διαφορά από το MLP.

Ο λόγος που ο Random Forest πήγε καλύτερα είναι επειδή λειτουργεί συνδυάζοντας πολλά δέντρα αποφάσεων. Αυτό τον βοηθάει να μην κάνει εύκολα λάθος όταν υπάρχουν θόρυβοι στα δεδομένα, σε αντίθεση με τα μονά μοντέλα. Επίσης, στο dataset credit-g που έχει και αριθμούς και λέξεις (κατηγορίες), τα δέντρα λειτουργούν πολύ καλύτερα από τον k-NN. Τέλος, ο Random Forest δουλεύει καλά ακόμα και με τις βασικές ρυθμίσεις, ενώ το MLP χρειάζεται πολλές ρυθμίσεις για να αποδώσει σωστά.

Πώς επηρέασε η προεπεξεργασία τα αποτελέσματα;

Η προεπεξεργασία των δεδομένων ήταν απαραίτητη για να τρέξουν σωστά οι αλγόριθμοι. Η κανονικοποίηση με τον StandardScaler βοήθησε πολύ τον k-NN και το MLP. Ο k-NN μετράει αποστάσεις, οπότε αν δεν είχαμε κανονικοποιήσει τα δεδομένα, τα χαρακτηριστικά με μεγάλες τιμές θα επηρέαζαν το αποτέλεσμα περισσότερο από τα υπόλοιπα. Το ίδιο ισχύει και για το MLP, το οποίο εκπαιδεύεται πιο εύκολα όταν τα δεδομένα είναι στην ίδια κλίμακα.

Επίσης, η κωδικοποίηση One-Hot ήταν αναγκαία για το dataset credit-g, ώστε να μετατραπούν οι λέξεις σε αριθμούς και να μπορούν να τα επεξεργαστούν τα μοντέλα. Τέλος, η συμπλήρωση των κενών τιμών κράτησε τα δεδομένα μας πλήρη χωρίς να χάσουμε πληροφορία.

Ποιοι αλγόριθμοι είναι πιο ευαίσθητοι στις υπερπαραμέτρους;

Το MLP (Νευρωνικό Δίκτυο) είναι ο πιο ευαίσθητος αλγόριθμος από τους τρεις. Κατά την εκτέλεση εμφανίστηκε μήνυμα ότι δεν ολοκληρώθηκε πλήρως η εκπαίδευση στις 500 επαναλήψεις. Αυτό δείχνει ότι το MLP εξαρτάται πολύ από τις ρυθμίσεις του, όπως τον αριθμό των νευρώνων και τον ρυθμό μάθησης. Αντίθετα, ο Random Forest είναι πιο σταθερός και δεν αλλάζει εύκολα η απόδοσή του αν αλλάξουμε λίγο τις παραμέτρους. Ο k-NN επηρεάζεται κυρίως από τον αριθμό των γειτόνων.

Πλεονεκτήματα και μειονεκτήματα κάθε προσέγγισης

Ο Random Forest είναι πολύ καλός όταν έχουμε δεδομένα που δεν είναι όλα αριθμοί, όπως στο credit-g, και είναι σταθερός χωρίς να θέλει πολλές ρυθμίσεις. Το μειονέκτημά του είναι ότι μπορεί να γίνει λίγο πιο αργός όταν έχει πολλά δέντρα.

Το MLP κατάφερε να πιάσει την καλύτερη ακρίβεια στο diabetes, που σημαίνει ότι είναι δυνατό σε δύσκολα προβλήματα. Όμως, είναι δύσκολο να ρυθμιστεί σωστά, χρειάζεται οπωσδήποτε κανονικοποίηση και αργεί να εκπαιδευτεί.

Ο k-NN είναι απλός και γρήγορος στην εκπαίδευση και πήγε πολύ καλά στο εύκολο dataset (breast-w). Ωστόσο, στο credit-g είχε τη χαμηλότερη απόδοση γιατί δυσκολεύεται όταν υπάρχουν πολλά χαρακτηριστικά και ειδικά μετά την κωδικοποίηση των κατηγοριών.

Πίνακας σύγκρισης αποτελεσμάτων

...

--- Συγκριτικός Πίνακας Αποτελεσμάτων ---

	Dataset	Algorithm	Accuracy	Precision	Recall	F1-Score
1	breast-w	Random Forest	0.9671	0.9645	0.9641	0.9637
0	breast-w	k-NN	0.9643	0.9623	0.9600	0.9604
2	breast-w	MLP (Neural Net)	0.9643	0.9599	0.9619	0.9604
7	credit-g	Random Forest	0.7540	0.7197	0.6490	0.6604
8	credit-g	MLP (Neural Net)	0.7330	0.6783	0.6645	0.6699
6	credit-g	k-NN	0.7200	0.6564	0.6067	0.6120
5	diabetes	MLP (Neural Net)	0.7644	0.7436	0.7299	0.7349
4	diabetes	Random Forest	0.7631	0.7449	0.7185	0.7266
3	diabetes	k-NN	0.7357	0.7093	0.6923	0.6980